# ML-baserat beslutsunderlag – California Housing

## 1) Mål & valt spår

Syftet med denna uppgift är att se om maskininlärning kan användas som stöd för att uppskatta bostadsvärde i olika områden i Kalifornien.

Jag valde **Spår A (Regression)** eftersom vi ska förutsäga ett numeriskt värde, som är `median_house_value`. Jag tycker detta spår är mer tydligt eftersom vi direkt försöker räkna ut ett värde.

---

## 2) Kort data-insikt (EDA)

När jag tittade på datan först såg jag några saker:

- Medianinkomst verkar ha samband med bostadsvärde. Om inkomsten är högre är ofta bostadsvärdet också högre.
- Områden nära havet verkar ofta ha högre priser än inlandet.
- Datan är per område och inte per enskilt hus, så det är mer en översikt.

Jag skapade också nya variabler, till exempel antal rum per hushåll, för att göra datan lite mer jämförbar.

---

## 3) Metod (ML-flöde)

Jag delade datan i träningsdata och testdata (80/20). Testdatan används för att kontrollera hur modellen fungerar på ny data.

Eftersom det fanns saknade värden använde jag imputering (median). Jag använde också scaling på numeriska variabler och One-Hot Encoding för den kategoriska variabeln `ocean_proximity`.

Jag använde pipelines för att samla preprocessing och modell i samma steg. Jag gjorde detta för att undvika fel och leakage.

Jag testade två modeller:

- Linear Regression (en enkel modell)
- Random Forest (en mer flexibel modell)

Jag använde MAE, RMSE och $R^2$ för att utvärdera modellerna.

---

## 4) Resultat

Random Forest fungerade bättre än Linear Regression på testdatan.

Ungefärliga resultat:

Linear Regression

- RMSE ≈ 69 000
- $R^2 \approx 0.63$

Random Forest

- RMSE ≈ 49 000
- $R^2 \approx 0.81$

Det betyder att Random Forest gör mindre fel i genomsnitt.

---

## 5) Rekommendation

Baserat på resultaten skulle jag rekommendera Random Forest som beslutsstöd. Den ger bättre resultat i denna uppgift.

Men modellen är inte perfekt och bör bara användas som stöd, inte som exakt värdering.

---

## 6) Risker & begränsningar

Det finns några begränsningar:

- Datan är per område och inte per hus.
- Modellen är tränad på historisk data och marknaden kan ändras.
- Resultaten är uppskattningar och inte exakta värden.

---

## 7) Oövervakad inlärning

Oövervakad inlärning används när man inte har en target och vill hitta struktur i datan.

Jag använde:

- **PCA** för att få en enklare bild av datan i två dimensioner.

- **KMeans** för att se om områden kan delas in i grupper.

Jag såg att det finns vissa skillnader mellan grupper, till exempel i inkomst och hushållsstruktur. Men resultatet beror på val av variabler och antal kluster, så det är inte helt säkert.

---

# 8) Självreflektion

Detta är första gången jag gör en hel maskininlärningsanalys själv från början till slut. Det var lite svårt att förstå alla steg i preprocessing och varför de behövs.

Jag tycker att jag har följt uppgiftens krav och försökt arbeta strukturerat.